

README – Umfrage-Auswertung

Dieses Tool macht die Auswertung für Likert-Fragen möglichst geradlinig:

1. **Rohdaten-CSV** einlesen (Antworttexte wie „Teils/teils“, „Stimmt eher zu“...).
 2. **Mapping-CSV** einlesen (Text → Zahlencode).
 3. **Include-CSV** einlesen (welche Frage-Nummern ausgewertet werden sollen).
 4. Aus den **kodierten Zahlen** werden Kennwerte und ein einfacher Signifikanztest berechnet.
-

Welche Dateien werden gebraucht?

1) Rohdaten (`raw.csv`)

- Spalten heißen in der Regel so:
`Frage <nummer> - <Fragetext>`
- Zellen enthalten Antworttexte oder manchmal schon Zahlen.

2) Mapping (`mapping.csv`)

Mindestens zwei Spalten:

- `value` (oder ähnlich): Antworttext
- `code` (oder ähnlich): Zahlencode

Beispiel:

value	code
Stimmt überhaupt nicht zu	1
Stimmt eher nicht zu	2
Teils/teils	3
Stimmt eher zu	4
Stimmt voll und ganz zu	5

Wichtig:

- Textvergleich ist **case-insensitive** (Groß/Klein egal).
- Wenn ein `value` fehlt oder `code` leer ist, wird die Zelle **NaN** (nicht auswertbar), bis das Mapping ergänzt ist.

3) Include-Liste (`include_questions.csv`)

Eine Spalte mit Frage-Nummern, z. B.:

```
question_number
4
6
7
...
```

Nur diese Fragen werden verarbeitet (alles andere wird ignoriert). Sinnvoll ist hier: **nur Fragen, die wirklich Likert-Skalen-Antworten haben**. Freitext oder kategoriale Fragen bringen für diesen Signifikanztest nichts.

Was kommt raus?

`codeddata_included.csv`

Rohdaten, aber überall Zahlen:

- leere Zelle → NaN
- numerischer Text (z. B. „3“) → 3
- Antworttext → Mapping-Code
- unbekannter Antworttext → NaN

`descriptives_included.csv`

Pro Spalte (Frage) Kennwerte:

- `n` (wie viele gültige Werte)
- `mean` (Durchschnitt)
- `median` (Median)
- `std` (Standardabweichung, Stichprobe)
- `min, max`

`likert_stats_included.csv`

Zusätzlich (nur für als Likert erkannte Spalten):

- `c1..c5`: Häufigkeiten der Codes 1..5 (bei 3-stufig entsprechend)
 - `k_above, k_below, ties, m_no_ties`
 - `p_value + significant`
-

Wie wird „Signifikanz“ hier verstanden?

Es gibt keinen Vergleich zwischen zwei Prototypen oder Gruppen.

Signifikanz bedeutet hier:

Weicht die Bewertung systematisch vom neutralen Mittelpunkt ab?

- Bei 1–5 Skalen ist der Mittelpunkt **3**
- Bei 1–3 Skalen ist der Mittelpunkt **2**

Als Test wird ein **zweiseitiger Sign-Test** genutzt, hier eine gute Ressource dazu <https://statistikguru.de/spss/wilcoxon-vorzeichen-rang-test/voraussetzungen-19.html> (<https://statistikguru.de/spss/wilcoxon-vorzeichen-rang-test/voraussetzungen-19.html>).

Sign-Test – kurz erklärt

Die Idee: Antworten werden in drei Kategorien gepackt:

- **unterhalb** des Mittelpunkts
- **genau** am Mittelpunkt (**ties**)
- **oberhalb** des Mittelpunkts

Ties werden für den Test ignoriert, weil sie „weder noch“ sind und die Frage hier ist:

geht es eher nach oben oder eher nach unten weg vom neutralen Punkt?

Dann wird geprüft, ob „oberhalb“ und „unterhalb“ ungefähr 50/50 sind (Nullhypothese).

Allgemeines zur Berechnung

Was bedeutet was

- $P(\dots)$ => „Wahrscheinlichkeit von ...“
- x => Zufallsvariable, Anzahl der Antworten, die auf der „selteneren Seite“ liegen (also entweder unterhalb oder oberhalb des Mittelpunkts)
- m => Anzahl Antworten ohne ties (m_no_ties)
- $p = 0,5$ => Wahrscheinlichkeit für „oberhalb“; genauso 0,5 für „unterhalb“
- „ $X \sim \text{Binomial}(m, 0.5)$ “ => X verhält sich wie ein Ergebnis aus m Münzwürfen mit Trefferwahrscheinlichkeit 0,5.

Was ist der p-Wert (p_value)?

Der p-Wert ist:

Wie wahrscheinlich wäre ein Ergebnis mindestens so extrem wie das beobachtete, wenn es eigentlich keinen echten Trend gibt (Nullhypothese)?

Klein = „Das wäre unter Zufall eher selten“

Groß = „Das kann gut durch Zufall passieren“

Für die wissenschaftliche Auswertung wollen wir einen kleinen p-value. Immerhin wollen wir zeigen, dass unsere Ergebnisse Korrelationen/Gründe abbilden und nicht reiner Zufall sind.

Warum ist das „zweiseitig“?

„Zweiseitig“ heißt: Es ist egal, ob die Abweichung nach oben oder nach unten geht, beides ist „auffällig“.

Darum wird am Ende mal 2 gerechnet.

Beispielrechnung mit echten Daten aus `likert_stats_included.csv`

Beispielzeile:

- **Frage 20 - Bitte bewerten Sie die folgenden Punkte. - Ich halte diese Vorhersage für glaubwürdig. / (Spalten 1-5)**
- Skala: **1–5**, Mittelpunkt: **3**
- **n = 14**
- **mean = 1.785714**
- **median = 2.0**
- **std = 0.425815**
- Häufigkeiten:
c1=3, c2=11, c3=0, c4=0, c5=0

Schritt 1: in „below / ties / above“ umrechnen (bei 1–5)

Bei 1–5 ist „neutral“ die 3.

- **below = c1 + c2 = 3 + 11 = 14**
- **ties = c3 = 0**
- **above = c4 + c5 = 0 + 0 = 0**

Schritt 2: Ties entfernen

- $m_no_ties = above + below = 0 + 14 = 14$

Das ist die Anzahl Antworten, die wirklich „eine Richtung“ haben (nicht neutral).

Schritt 3: Sign-Test rechnen

- Es gibt $m_no_ties = 14$ Antworten ohne ties.
- Unter der Nullhypothese wäre „oben“ und „unten“ 50/50.
Also wäre es nicht ungewöhnlich, wenn z. B. 7 oben und 7 unten sind.
- Beobachtet wurde aber: 0 oben und 14 unten. Das ist extrem einseitig.

So wird der p-Wert berechnet:

1. Man nimmt die kleinere Seite: $k = \min(above, below)$
→ $k = \min(0, 14) = 0$
2. Man fragt: Wie wahrscheinlich ist es bei 14 „Münzwürfen“ (50/50), dass die kleinere Seite so klein ist wie 0?
 - $P(X \leq 0)$ bedeutet hier: „Wahrscheinlichkeit, dass X genau 0 ist“
3. Bei fairer Münze ist:
 - Wahrscheinlichkeit für „14 mal gleiche Richtung“ = $(0.5)^{14}$
4. zweiseitig wird verdoppelt:
 - $p = 2 * (0.5)^{14}$
 - $p = 0.0001220703$

Das entspricht dem p-Wert in der Datei:

- $p_value = 0.0001220703$

Schritt 4: Interpretation mit Alpha (α)

α ist eine vorher festgelegte Grenze, ab wann etwas als „statistisch auffällig“ gilt.

*Der Standardwert ist oft **0.05**, weil das historisch/konventionell in vielen Feldern so genutzt wird.*

Was bedeutet $\alpha = 0.05$ praktisch?

Wenn die Nullhypothese stimmt (kein echter Effekt), dann akzeptiert man bei $\alpha=0.05$, dass man in etwa **5% der Fälle** trotzdem „signifikant“ sagt (Fehlalarm/False Positive).

In diesem Beispiel:

- $p_value = 0.000122\dots$ ist viel kleiner als 0.05
→ Ergebnis ist **signifikant**.

Inhaltlich heißt das:

- Antworten liegen **sehr deutlich unter dem Mittelpunkt (3)**
(weil fast alles bei 1–2 ist).
 - Das spricht eher gegen „glaubwürdig“ (je nachdem, wie die Skala gepolt ist).
-

Wie sollte das im Text interpretiert werden?

- **Median** ist bei Likert oft die wichtigste Zahl („wo liegt die Mitte?“).
- **mean** kann man zusätzlich berichten, aber er ist empfindlicher.
- **std** zeigt, wie stark sich Antworten streuen.
- **p_value** beantwortet nur: „Abweichung vom Mittelpunkt ist auffällig oder nicht also weicht es GENUG vom Mittelpunkt ab?“

*Wichtig: „Nicht signifikant“ heißt bei kleinen Stichproben oft nur: **zu wenig Daten** / **zu wenig Power**.*

Starten

```
pip install -r requirements.txt  
streamlit run main.py
```